

晶創26/25 GPU叢集教育訓練

方育斌、周朝宜

教材：https://github.com/robinfang7/nchc_hpc_tutorial

Agenda

1. 從0到1，用超級電腦訓練YOLO網路
2. 國網中心的GPU叢集系統介紹
 1. 晶創26、晶創25
 2. iService計算資源服務網
3. 叢集系統的軟體
 1. Slurm任務調度
 2. Lmod軟體管理
 3. Singularity/Apptainer容器
 4. 安裝軟體
4. 實作展示
5. 問題與討論

從0到1，用超級電腦訓練YOLO網路

1.執行前，確認主機帳號(含OTP載具)、計畫代號、錢包

計畫類別：政府與法人計畫

*計畫名稱：NCHC-效能量測小組-TWCC

*計畫系統代號：GOV■■■■32

*所屬專業領域：工程技術類 - 資訊工程、智慧計算

計畫編號：

*開始時間：2019-06-17

~

*結束時間：2026-12-31

申請服務：

臺灣AI雲(TWCC)(網站)

台灣杉三號(網站)

計畫錢包：

▶ 計畫錢包總額度: 13,388,642.5

計畫額度：

▶ 計畫可用額度: 880,017.7

▶ 母子錢包餘額: 880,017.7

修改主機帳號基本資料

主機帳號

主機帳號

██████████ (啟用)

主機密碼

變更主機密碼

最近一次變更主機密碼日期：2026-07-27
10:43:21

OTP 載具：有效

刪除使用者載具

最近一次成功刪除載具日期：2026-03-28
19:42:17

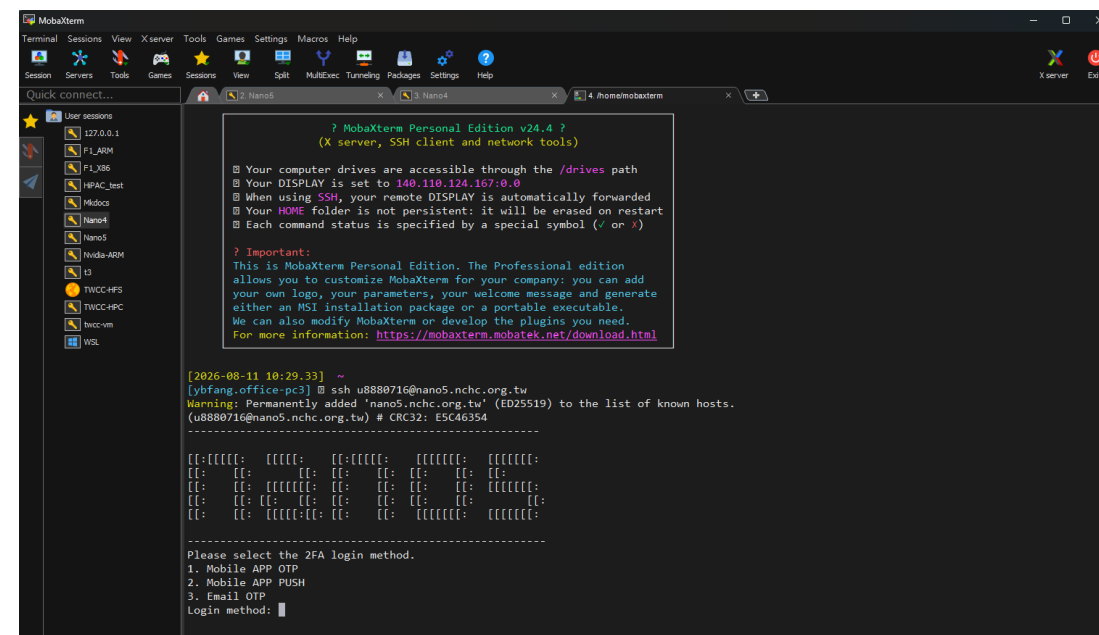
注意：已發送APP 載具註冊通知信件

使用 IDExpert 手機 APP (APP OTP 或 Push) 進行登入節點雙因子(2FA) 驗證作業前，請至 ██████████@gmail.com 信箱收取載具註冊通知信件，並依內容指示完成 APP 載具註冊作業。

► Email OTP 電子郵件：██████████@gmail.com

Connect to Nano4/5 via SSH tool

- ssh 主機帳號@nano5.nchc.org.tw
- ssh 主機帳號@nano4.nchc.org.tw




在終端機介面查詢計畫錢包 wallet <ProjectID>

```

[u8880716@25a-lgn02 ~]$ wallet gov ████████ 32
PROJECT_ID: GOV ████████ 032, PROJECT_NAME: NCHC-效能量測小組-TWCC, SU_BALANCE: 880017.6909
  
```

2. 訓練YOLO模型前的環境安裝



```
import torch;
print(f'PyTorch: {torch.__version__}\n
CUDA: {torch.version.cuda}\n
ncuDNN: {torch.backends.cudnn.version()}');
```

Ultralytics-8.4.115 container

```
nvidia-cublas-cu12 12.8.4.1
nvidia-cuda-cupti-cu12 12.8.90
nvidia-cuda-nvrtc-cu12 12.8.93
nvidia-cuda-runtime-cu12 12.8.90
nvidia-cudnn-cu12 9.19.0.56
```

```
torch 2.11.0+cu128
torchaudio 2.11.0+cu128
torchvision 0.26.0+cu128
```

```
PyTorch: 2.11.0+cu128
CUDA: 12.8
cuDNN: 91900
```

uv add ultralytics


```
nvidia-cublas 13.1.1.3
nvidia-cuda-cupti 13.0.85
nvidia-cuda-nvrtc 13.0.88
nvidia-cuda-runtime 13.0.96
nvidia-cudnn-cu13 9.20.0.48
```

```
torch 2.13.0
torchvision 0.28.0
```



```
PyTorch: 2.13.0+cu130
CUDA: 13.0
cuDNN: 92000
```

3. 訓練YOLO模型

https://github.com/robinfang7/nchc_hpc_tutorial/tree/main/yolo



高效能計算 VS 雲端計算

	高效能計算	雲端計算
目的	AI模型訓練、科學工程模擬分析、計算	架設網站、系統、服務、資料庫
使用時間	使用數天，計算完會自動歸還資源	可長期使用
國網服務項目	晶創26/25、創進一號	晶創雲
底層系統	Slurm / PBS	OpenStack / Vmware
基本電腦單位	計算節點	虛擬機器
使用多台電腦的動機	大規模尺度的平行計算	保持系統的高可用性與容錯率
架構圖	 The diagram illustrates the HPC architecture. A User (使用者) connects to a Login Node (登入節點) via SSH (Secure Remote Access). The Login Node handles Slurm Commands (Job Submission) and manages job submission and management. It then connects to a cluster of 3 Compute Nodes (計算節點群), which execute computational tasks. Data is accessed from a 4: HFS (高速檔案系統) storage system, specifically the /home, /work directories.	 The diagram compares two cloud computing architectures. On the left, Virtual Machines (VMs) are shown with a stack: Infrastructure, Hypervisor, Guest OS, Bins/Lib, and App. On the right, Containers are shown with a stack: Infrastructure, Operating System, Container Engine, Bins/Lib, and App. Both architectures support multiple applications (App 1, App 2, App 3).

<https://www.virtasant.com/blog/hypervisors-a-comprehensive-guide>

晶創26 Nano4

- 「晶創26」為國家推動AI、高效能運算與科研自主能力的重要基礎設施，更是主權AI與技術自主發展的關鍵推手。採用雙重算力架構設計，包括「Nano4」（H200 架構系統），以及最新一代的GB200 NVL72架構節點，兼具通用科學模擬與AI訓練的高效能運算需求。其中「Nano4」於2025年11月首次於Top50排行，實測最佳用電功率為 2.214 百萬瓦（MW），峰值(Rpeak)達 117.92 PFlops，實測效能（Rmax）為81.55 PFlops，為目前臺灣最快、運算密度最高的超級電腦。
- 除「Nano4」之外，晶創26另一套系統NVIDIA GB200 NVL72，則是NVIDIA 2025年新推出的旗艦級AI運算平台，由國研院國網中心領先全臺首次導入，每座搭載多達72顆Blackwell GPU與13.5TB記憶體，具備極高AI訓練效能，展現臺灣在先進AI基礎設施布建的前瞻眼光與技術實力。



晶創25 Nano5


- 晶創25(英文名稱：Nano 5)為新一代加速器叢集式超級電腦，計有21台NVIDIA H100以及16台NVIDIA H200 AI伺服器，共有296片NVIDIA Hopper計算加速器，為台灣發展AI及高效能運算的關鍵基礎設施。晶創主機也承襲「晶創計畫」的願景，助力半導體產業發展AI應用，也為半導體產業其他各種應用及研發，提供強大且高速的計算環境。
- 晶創25主機採用NVIDIA Hopper計算加速器，於2025年6月TOP500首次排行118名，算力(Rmax)達13.06PetaFLOPS，可大幅提升人工智慧模型訓練與科學模擬的運算效率。此主機適用於產業界、政府機構、學術單位以及研究機構，為各類用戶提供高效能的運算支援，助力AI全面推動。



GPU主機規格

	晶創26	晶創25
建置時間	2025/11	2025/6
總算力	81.55 PFLOPS	16.03 PFLOPS
節點數	220台NVIDIA H200+ 2櫃NVIDIA GB200 NVL72	21台H100節點+16台H200節點
檔案系統總容量	25PB	9.3 PB
節點CPU	2 x Intel Xeon Platinum處理器/ 72 x NVIDIA Grace處理器	2顆Intel Xeon(R) Platinum 8480+(8480CL)
節點GPU	8張NVIDIA H200 GPU/ 72 x Blackwell GPU /櫃	8片NVIDIA H100 GPU 8片NVIDIA H200 GPU
節點記憶體容量	2TB / 13.5TB	2TB
網路頻寬	InfiniBand NDR 400 Gb/s	計算伺服器間以8個Infiniband NDR 400Gbs網路埠連接 以2個 Infiniband NDR 200Gbs網路埠連接至儲存系統
CUDA version	13.0	12.4

DGX H100/200 System Topology



ConnectX-7 ConnectX-7 Network Modules NVMe PCIeSwitch NVSwitch PCIe 100 GbE CPU communication

GPU Spec

規格項目	NVIDIA H100 SXM	NVIDIA H200 SXM	NVIDIA GB200 Grace Blackwell 超級晶片
架構 (Architecture)	Hopper	Hopper	Blackwell (GPU) + Grace (CPU)
晶片組成	1x GH100 GPU	1x GH100 GPU	1x Grace CPU + 2x Blackwell GPU
電晶體數量	800 億	800 億	4,160 億 (約 2,080 億/GPU)
GPU 記憶體容量	80 GB	141 GB	384 GB (192 GB × 2 GPU)
GPU 記憶體頻寬	3.35 TB/s	4.8 TB/s	16 TB/s (8 TB/s × 2 GPU)
FP64 運算性能	34 TFLOPS	34 TFLOPS	80 TFLOPS
FP32 運算性能	67 TFLOPS	67 TFLOPS	160 TFLOPS
TF32 Tensor 運算	1,000 TFLOPS (2,000 Sparse)	1,000 TFLOPS (2,000 Sparse)	2,500 TFLOPS (5,000 Sparse)
FP16 / BF16 Tensor 運算	1,979 TFLOPS (3,958 Sparse)	1,979 TFLOPS (3,958 Sparse)	5,000 TFLOPS (10,000 Sparse)
FP8 / INT8 Tensor 運算	3,958 TFLOPS (7,916 Sparse)	3,958 TFLOPS (7,916 Sparse)	10,000 TFLOPS (20,000 Sparse)
FP4 Tensor 運算	不支援	不支援	20,000 TFLOPS (40,000 Sparse)
互連技術 (Interconnect)	NVLink 4.0 (900 GB/s)	NVLink 4.0 (900 GB/s)	NVLink 5.0 (3.6 TB/s) + NVLink-C2C (900 GB/s)
最大熱設計功耗 (TDP)	最高約 700W	最高約 700W	約 2,700W (整顆超級晶片)
GPU小時費率	25/50/50/120	30/60/60/150	未開放

- <https://iservice.nchc.org.tw/>
- 提供國網中心各服務平台的帳戶申請及管理，包含計畫成員管理、預算和經費管理、使用資源報表查詢、平台操作技術支援等功能，其中計算資源申請服務，如創進一號、臺灣AI雲(TWCC)等，透過iService計算資源服務網提供服務。

特色：簡化申請流程、單一服務帳號



用戶自助管理

- 線上提出各項需求服務申請
- 建立計畫、自行設定邀請及管理成員




錢包管理

- 分配計畫成員錢包（可用量）
- 資源彈性調度



技術支援


- 操作Q&A
- 問題反應
- 服務快訊



報表查詢

- 使用量明細查詢
- 定期可用額度提醒

iService流程



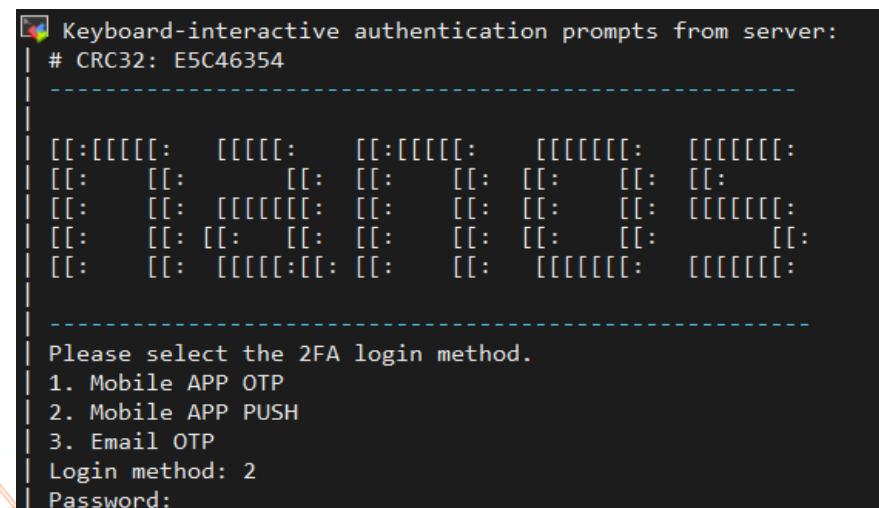
帳號有兩種

■ iService會員帳號

- 登入iService網站、
- 晶創雲、
- AI RAP、
- NCHC教育訓練網
- 帳號的格式是電子信箱

■ 主機帳號

- 登入晶創26/25主機，創進一號



主機帳號與OTP設定

會員中心>會員資訊>主機帳號資訊

iService
計算資源服務網

會員中心服務介紹操作說明常見問題

修改主機帳號基本資料

主機帳號

主機密碼

OTP 載具: 有效

主帳號
[REDACTED] (啟用)

變更主機密碼

刪除使用者載具


最近一次變更主機密碼日期: 2025-02-04 09:19:16

最近一次成功刪除載具日期:

注意: 已發送APP 載具註冊通知信件
使用 IDExpert 手機 APP(APP OTP 或 Push)進行登入節點雙因子(2FA) 驗證作業前, 請至 [REDACTED] 信箱收取載具註冊通知信件, 並依內容指示完成 APP 載具註冊作業。

▶ Email OTP 電子郵件: [REDACTED]

說明:
1. 登入節點雙因子(2FA) 驗證作業方式, 選項說明:
1). Mobile APP OTP: 需安裝APP, 並完成註冊作業。開啟 APP 後取得 OTP 碼以完成 2FA 驗證。
2). Mobile APP PUSH: 需安裝 APP, 並完成註冊作業。由 login node 觸發推播驗證機制至用戶的手機以完成 2FA 驗證。
3). Email OTP: 將透過您註冊於 iService E-mail 取得 OTP 驗證碼以完成 2FA 驗證。
2. 註冊與登入作業, 請參考線上說明文件。
3. 用戶更換手機需重新安裝 APP 或原安裝的 APP 刪除後重新安裝, 請參考線上說明文件第3點, 重建載具。
4. 透過 APP QRCode 進行註冊服務, 每位帳號僅可註冊一支手機。



申請計畫(計劃管理者)

會員中心>計劃管理>我的計畫>新增



申購額度(計劃管理者)

會員中心>申購管理>申購計畫額度

會員中心 » 申購管理 » 申購計算額度 » 購買額度



購買額度說明

1.申請方式

由計畫主持人或管理員登入此申請網頁後，請點選會員中心→計畫管理→我的訂單→購買額度→選擇欲購買的計畫擇欲購買的計畫

2.使用額度與收費費率

2.1.帳號之使用額度與收費標準皆以核心小時或GPU小時為計算服務單位

核心小時(core-hour) = 執行小時數 × 計算核心

GPU小時 (GPU小時) = 執行小時數 × GPU 數

2.2. 計價方式

TWCC臺灣AI雲：[價目表](#)

加入成員(計劃管理者)

[會員中心](#) [服務介紹](#) [操作說明](#) [常見問題](#)

[計劃資訊](#) [付款方式](#) [成果登錄](#) [訂單資訊](#) [計畫成員](#) [服務申請](#) [錢包管理](#) [錢包異動紀錄](#) [額度用量](#)
[資源用量紀錄](#) [線上提問](#) [服務啟用狀態](#) [用量統計](#) [帳務總表](#)

你可以選擇 [+](#) 增加計畫成員 選擇 [≡](#) 進行人員的檢視、刪除及設定管理員

[+](#)

成員數：8，未認證：0

姓名	權限	主機帳號	會員帳號	職稱	所屬機關	狀態	動作
----	----	------	------	----	------	----	----

新增成員

×

請輸入欲邀請加入此計畫成員的會員帳號，按enter鍵後可繼續輸入。

user1@gmail.com x

user2@gmail.com x

新增

高速檔案系統 HFS Hyper File System

	晶創25/26
免費額度	/home 100GB /work 100GB (國科會計畫1536GB)
最高容量	/home 10240 GB (10TB) /work 204800 GB (200TB)
Hostname	晶創26：nano4.nchc.org.tw 晶創25：nano5.nchc.org.tw
Port	port 2222

收費方法：每日計費，每天根據前一日的用量平均值進行扣款，以更實際地反應用戶的使用情況。

HFS儲存空間：(*Home、Work與Project 費率相同) (單位：元)

計畫類型	每日1 GB
國科會計畫	0.0069
學術計畫	0.035
政府與法人計畫	0.07
企業與個人計畫	0.14

https://man.twcc.ai/iPIMu_XGQcCNNTryJMAPmg

https://man.twcc.ai/@nano4-manual/documentation/https%3A%2F%2Fman.twcc.ai%2F%40nano4-manual%2FBydP-_lvZq

https://iservice.nchc.org.tw/nchc_service/nchc_service_qa_single.php?qa_code=802

設定與查詢HFS 容量(計劃管理者)

計劃建立者和管理者有權限設定HFS容量

會員中心>設定HFS>Nano5/Nano4

會員中心 服務介紹 操作說明 常見問

1

會員資訊	▶	
計畫管理	▶	
申購管理	▶	
設定高速檔案系統HFS	▶	
計算主機負載資訊	▶	
		高速檔案系統HFS(TWCC/T3 共用)
		高速檔案系統HFS(F1)
		高速檔案系統HFS(Nano5/Nano4 共用)

HFS User Portal » 晶創26-x86 成員管理

成員管理

異動紀錄

變更計畫

計畫編號: [模糊] 計畫名稱: NCHC-效能量測小組-TWCC 計畫有效日: 2026-12-31

編輯

姓名	權限	成員資訊	綁定權限	有效綁定
[模糊]	[模糊]	帳號: [模糊]	允許綁定: 管理者設定 Home: 最大可用空間 100GB Work: 最大可用空間 100GB	無

NCHC 高速檔案系統(HFS)目錄空間管理系統

國家實驗研究院
NATIONAL INSTITUTES OF APPLIED RESEARCH

平台

晶創26

請選擇

晶創25

晶創26

登入

2

切換平台

[模糊]

[模糊]

登出

晶創26-x86 個人管理

晶創26-x86 成員管理

HFS User Portal » 晶創26-x86 成員管理

成員管理

異動紀錄

計畫編號: [模糊]

計畫名稱: NCHC-效能量測小組-TWCC

計畫有效日: 2026-12-31

姓名	權限	成員資訊	綁定權限	有效綁定
[模糊]	[模糊]	[模糊]	綁定權限 ☐ 不允許 ☒ 管理者設定 Home: 最大可用空間 1024 GB Work: 最大可用空間 10240 GB	無

上一步

下一步

取消

1TB = 1024GB

在命列列介面查詢HFS容量

```
# Nano4/5
```

```
[user@cbi-lgn01 ~]$ hfsquota
```

PATH	USED	HARD LIMIT	USAGE %	STATUS
/home/user	264,538,181,632 B	10,995,116,277,760 B	2	ACTIVE
/work/user	11,766,642,118,656 B	219,902,325,555,200 B	5	ACTIVE


容量單位換算：264,538,181,632 bytes /1024/1024/1024=246GB

登入節點

■ SSH Tools

- ❑ MobaXterm, Putty for Windows
- ❑ Terminal for Mac and Linux
- ❑ VS code

■ 雙因子(2FA) 驗證



	Host name	Port
晶創26	nano4.nchc.org.tw	22
晶創25	nano5.nchc.org.tw	22

延伸2FA的三種登入方式

選擇 1. Mobile APP OTP

手機IDeprt軟體會出現登入請求，點擊左下角選項' OPT' ，輸入你看到的驗證碼，按enter完成認證。

選擇 2. Mobile APP PUSH

手機IDEpert軟體會出現登入請求，點擊左下角選項‘推播’後，點擊:heavy_check_mark:完成認證

選擇 3. Email OTP

信箱會有"登入驗證碼通知信"，輸入你看到的驗證碼，按enter完成認證。



[NCHC iService 服務網]登入驗證碼通知信，此密碼將於2026-06-26 12:01:10內有效 iService x

國家高速網路與計算中心 <iservice@nii.org.tw>
寄給我 ▾

6月26日週五 上午11:58

您好：

554239 為您的[NCHC iService 服務網] 登入驗證碼，

您於 2026-06-26 11:58:10 使用主機帳號 [REDACTED]，

此密碼將於 2026-06-26 12:01:10 內有效。

如果您未提交驗證請求，敬請儘速向本中心反應。

此封信件由系統自動寄送，請勿直接回信。

若有任何問題，歡迎隨時透過以下方式與我們連絡，我們將盡快為您服務，謝謝！

免付費客服專線 0809-091-365 (24小時客服專線)



或請點選 [免付費用戶諮詢](#)

國家高速網路與計算中心 客服小組 敬上

資料傳輸節點

- SFTP Tools
 - Filezilla, WinSCP, MobaXterm
 - sftp command
- 雙因子(2FA) 驗證

	Host name	Port
晶創26	nano4.nchc.org.tw	2222
晶創25	nano5.nchc.org.tw	2222





登入晶創25的互動式繪圖節點

Tools

- ThinLinc for Windows, Mac, and Linux
- MobaXterm for Windows


雙因子(2FA) 驗證

	Host name	Port
晶創主機	nano5.nchc.org.tw	22



HPC Cluster Software

- Slurm任務調度工具，取得、查詢計算資源、提交作業。
- Lmod環境管理工具，引用已安裝的編譯器、函式庫、應用程式。
- Singularity/Apptainer容器，引用已封裝依賴項與應用程式的獨立環境。



主機實作展示

1. LLM Fine-Tuning (SWIFT framework)
2. [Pytorch DDP](#)
3. [Horovod](#)



客服專線：0809-091-365

帳號與計畫諮詢信箱：iservice@niar.org.tw

技術諮詢信箱： isupport@nlar.org.tw